

RiskLens ML

DÉFAUT DE PAIEMENT · CARTES DE CRÉDIT

PROJET DE FIN DE BOOTCAMP · RESTITUTION

« Peut-on prévoir le défaut de paiement d'un client en se basant uniquement sur son comportement transactionnel des 6 derniers mois, malgré un manque d'informations économiques globales ? »

Une banque taïwanaise · 30 000 clients · avril à septembre 2005

Johan Machu · risklens-ml.streamlit.app

SOMMAIRE

Le déroulé

1 La question et son contexte

2 Comprendre et corriger les données

3 Les clients déjà en difficulté, puis le modèle

4 La démonstration en direct

5 La réponse, les limites et les recommandations

6 Vos questions

LA QUESTION

Six mois pour deviner le septième

> *« Peut-on prévoir **le défaut de paiement** d'un client en se basant uniquement sur **son comportement transactionnel des 6 derniers mois**, malgré **un manque d'informations économiques globales** ? »*

Avril	Mai	Juin	Juillet	Août	Sept.
facture	facture	facture	facture	facture	facture
paiement	paiement	paiement	paiement	paiement	paiement
note de la banque	note de la banque	note de la banque	note de la banque	note de la banque	note de la banque

→ **Octobre**

Le client paiera-t-il, ou fera-t-il défaut ?

LE CONTEXTE · TAÏWAN

Les données arrivent en pleine crise des cartes de crédit

Années 1990
Le nombre de banques double

2002 – 2005
Boom des cartes : la dette de cartes passe de 5 à 9 % du PIB

Avril → sept. 2005
Les 6 mois du dataset : les règles se durcissent, les impayés montent

Octobre 2005
Le client paie-t-il ? C'est ce qu'il faut prévoir

Fin 2005 – 2006
La crise éclate : dettes renégociées, endettement plafonné

2006 – 2007
Deux chercheurs étudient ces données, publiées en 2009

30 000
clients d'une vraie banque taïwanaise

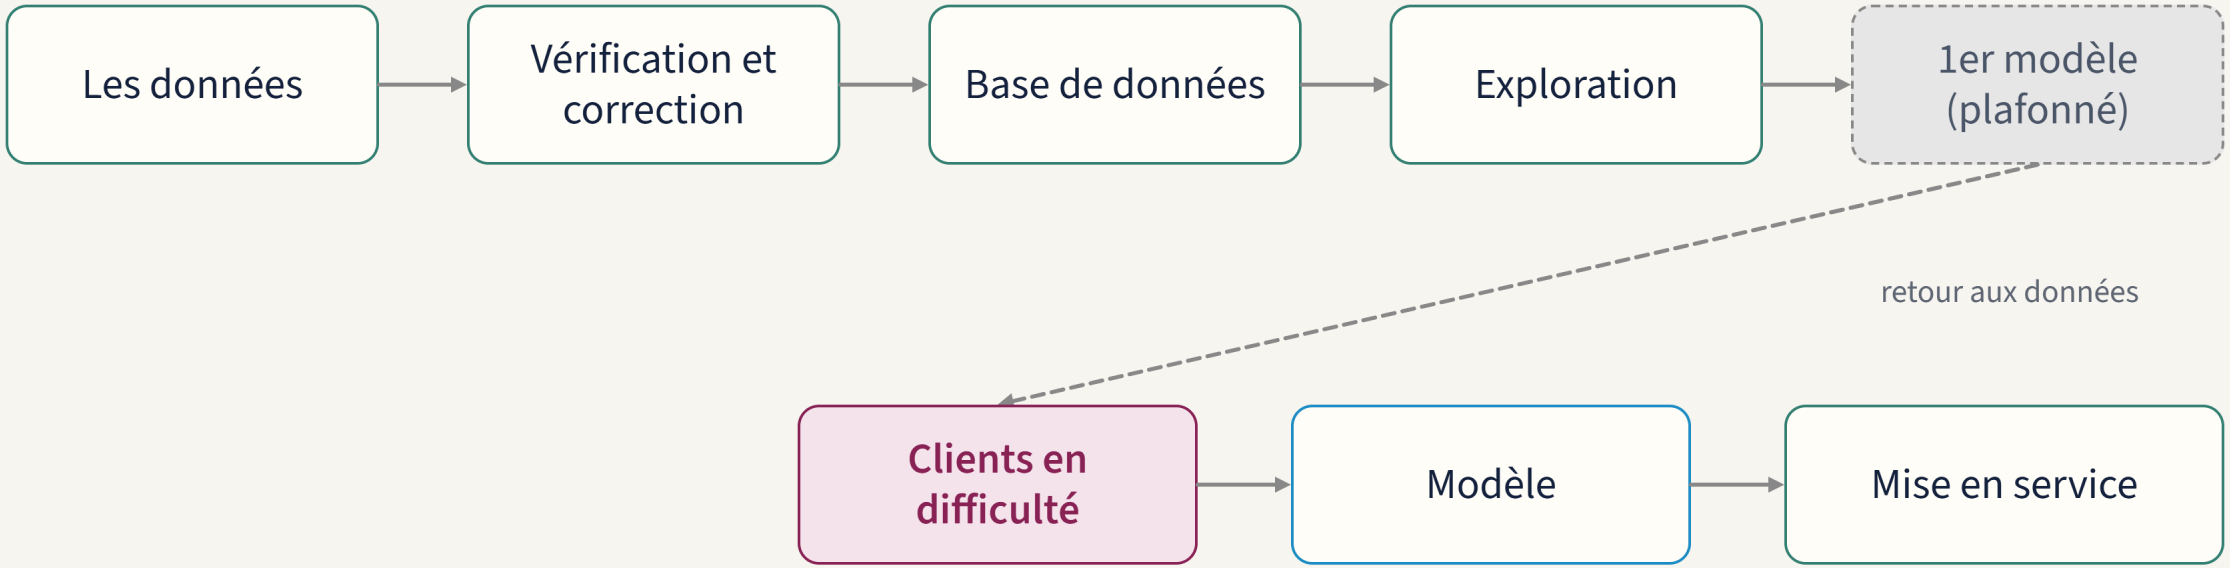
133
cartes pour 100 adultes en 2005

22,1 %
des clients ne paient pas en octobre

Une crise du crédit, pas de l'économie : chômage bas, croissance solide.

LA DÉMARCHE

Le chemin du projet



Le site internet, construit tout au long du projet

COMPRENDRE LES DONNÉES

Un fichier complet, mais des anomalies à comprendre

30 000

clients au départ

↓

28 851

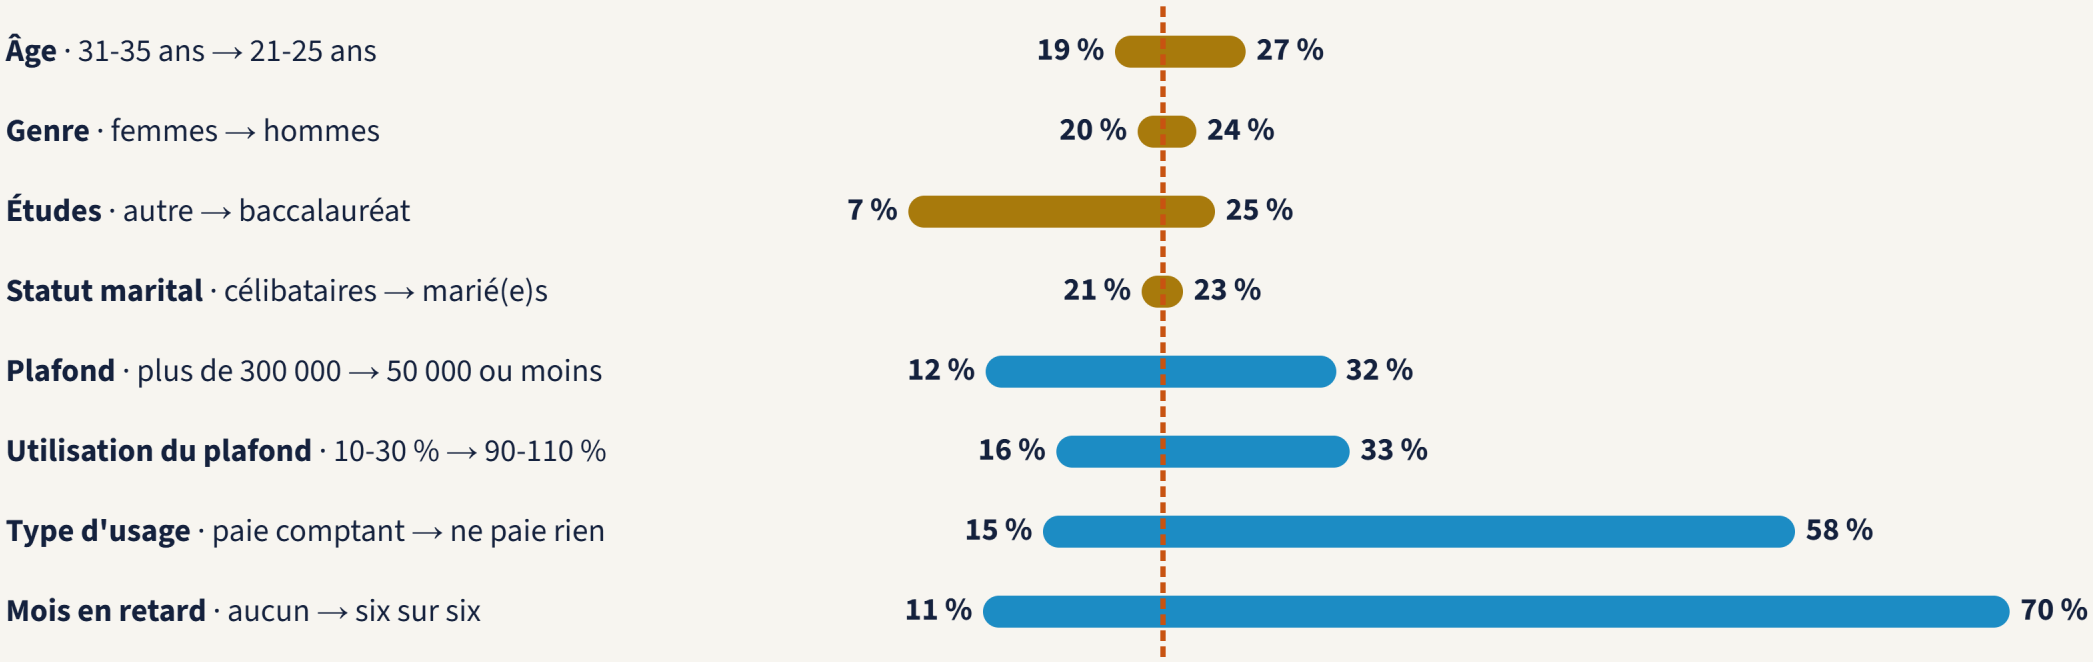
clients gardés, soit 96 %

Ce qu'on a trouvé	Ce qu'on en a fait
4 paiements géants, sans commune mesure avec les factures	Retirés
941 comptes sans aucune activité pendant six mois : rien à rembourser	Retirés
204 plafonds de plus de 500 000 NT$ (environ 12 500 €, un an de salaire moyen) : une clientèle à part	Retirés
Niveau d'études et statut marital : des valeurs absentes de la documentation	Ramenées à « autres »
Des codifications de paiement absentes de la documentation	Gardées, lues avec les paiements
Des notes « 1 » en septembre, inexpliquées	Corrigées
D'avril à juin, des clients qui ne paient presque rien restent notés à jour	Uniformisés : même règle de retard
Des clients sans aucune dette, pourtant notés en défaut	Gardés, une limite à retenir

Chaque anomalie reçoit une règle tirée du fonctionnement de la banque, jamais du résultat qu'on cherche à prévoir.

CE QUE MONTRENT LES DONNÉES

Le profil compte moins, le comportement beaucoup

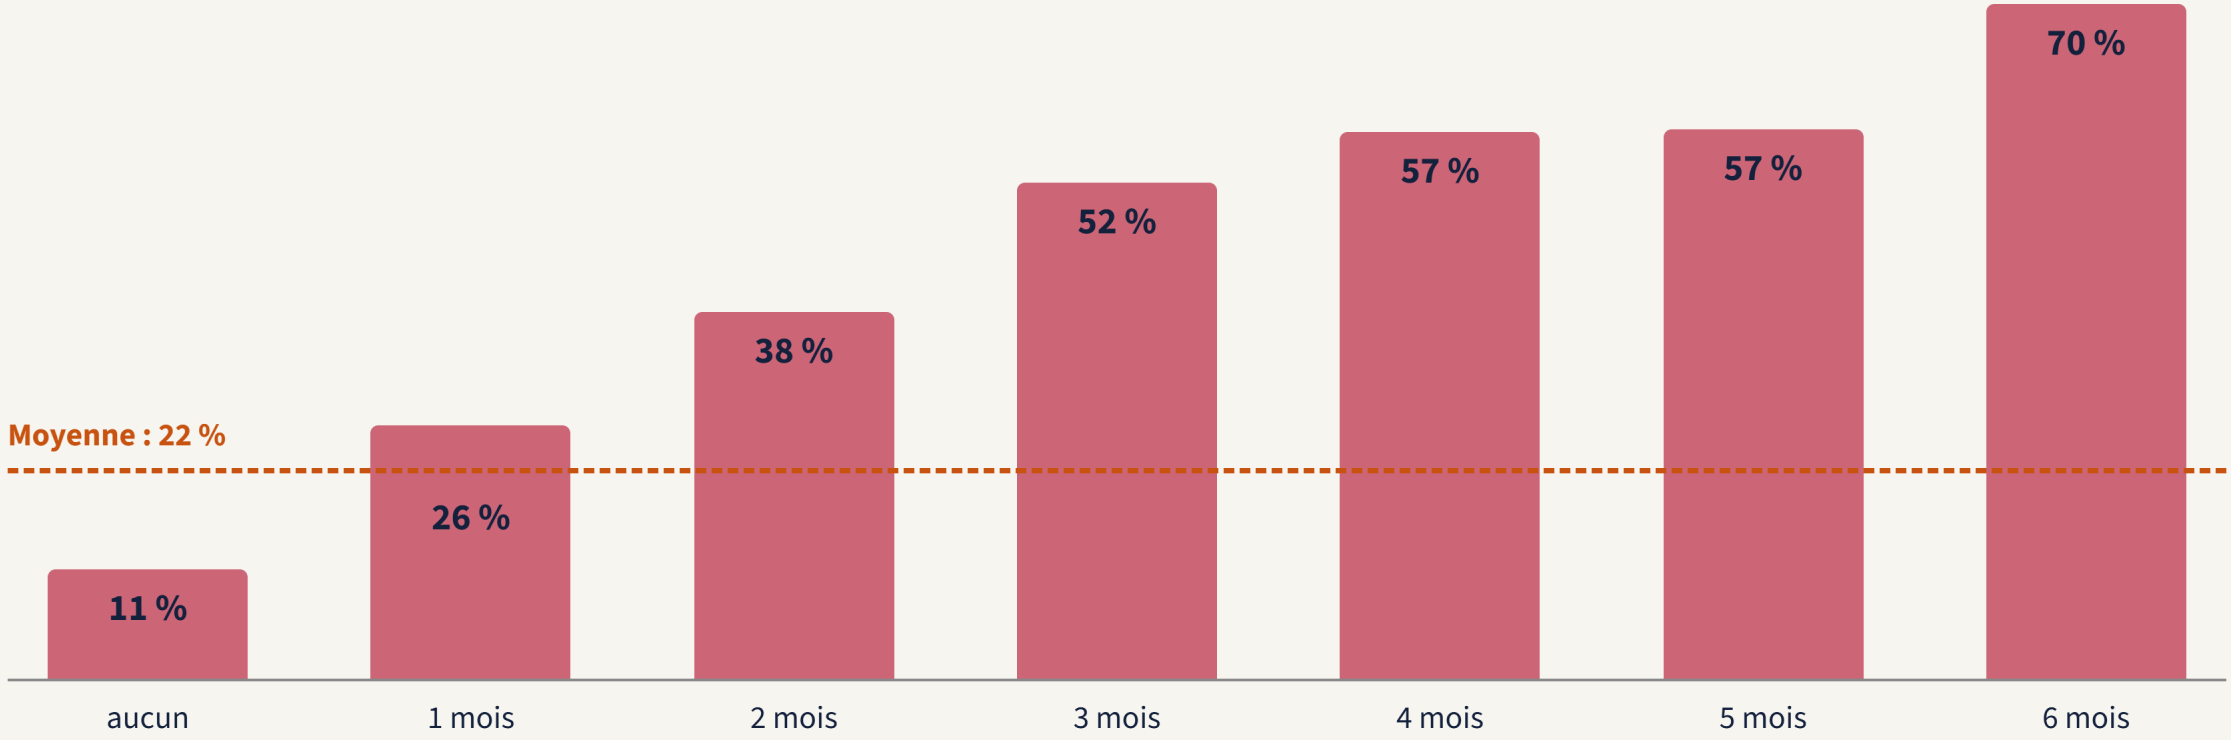


En ocre, le profil : des écarts plus modestes. En bleu, le comportement : de grands écarts, c'est lui qu'il faut suivre.

Chaque barre va du groupe le moins risqué au plus risqué ; part des clients en défaut ; groupes d'au moins 1 % des clients. Pointillés orange : moyenne, 22 %.

CE QUE MONTRENT LES DONNÉES

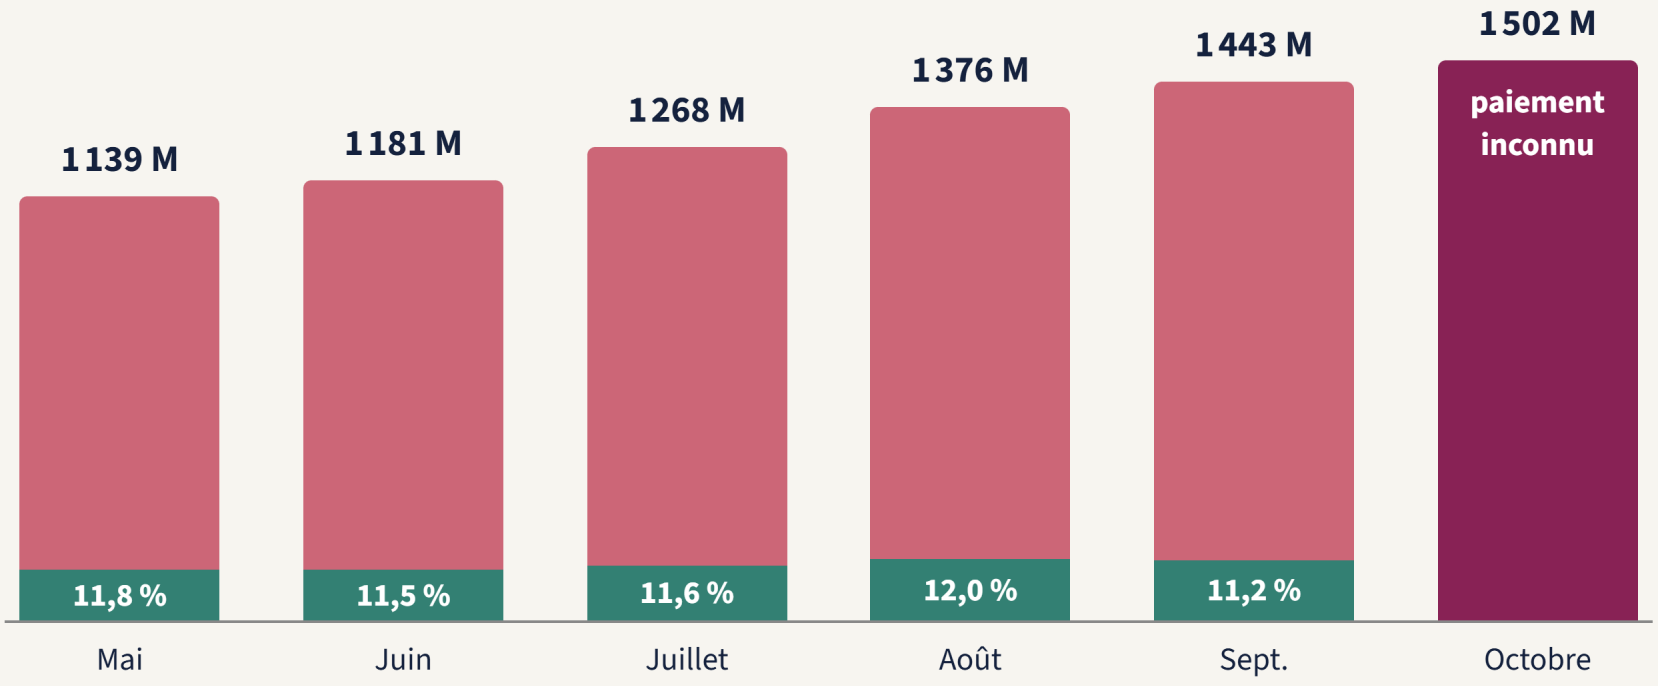
Plus les retards s'accumulent, plus le client fait défaut



Part des clients qui ne paient pas en octobre, selon le nombre de mois notés en retard sur six. Pointillés orange : tous les clients, 22 %.

LA CRISE DANS LES DONNÉES

La dette grossit, les clients en remboursent toujours aussi peu



Dette totale des 28 851 clients en fin de mois, en millions (M) de dollars taïwanais, face au paiement du mois suivant.

LES CLIENTS EN DIFFICULTÉ

Deux règles simples, sans modèle

Chaque mois, la banque note le client : **0** = à jour ; **2, 3…** = en retard de 2, 3 mois. Exemples pour illustrer :

	Avril	Mai	Juin	Juillet	Août	Sept.	
Client A	0	0	0	2	2	3	**En incident : prédit en défaut**
Client B	0	0	0	0	0	2	**Retard imminent : prédit en défaut**
Client C	0	2	0	0	0	0	Retard isolé, rattrapé : jugé par le modèle
Client D	2	3	0	0	0	0	Sorti de l'incident : jugé par le modèle



6 sur 10

des clients repérés par les deux règles ne paient pas

Mesuré sur des clients mis de côté dès le départ. Les règles viennent du fonctionnement de la banque ; le défaut n'a servi qu'à les vérifier.

UNE NOTION À POSER

Un modèle d'intelligence artificielle, c'est quoi ?

Des clients du passé

On connaît leur historique et la fin de l'histoire : ont-ils payé ?

Le modèle apprend

Il repère les comportements qui précèdent souvent un défaut

Un nouveau client

Le modèle compare son historique à ce qu'il a appris

Une note de risque

Il range les clients du plus risqué au moins risqué



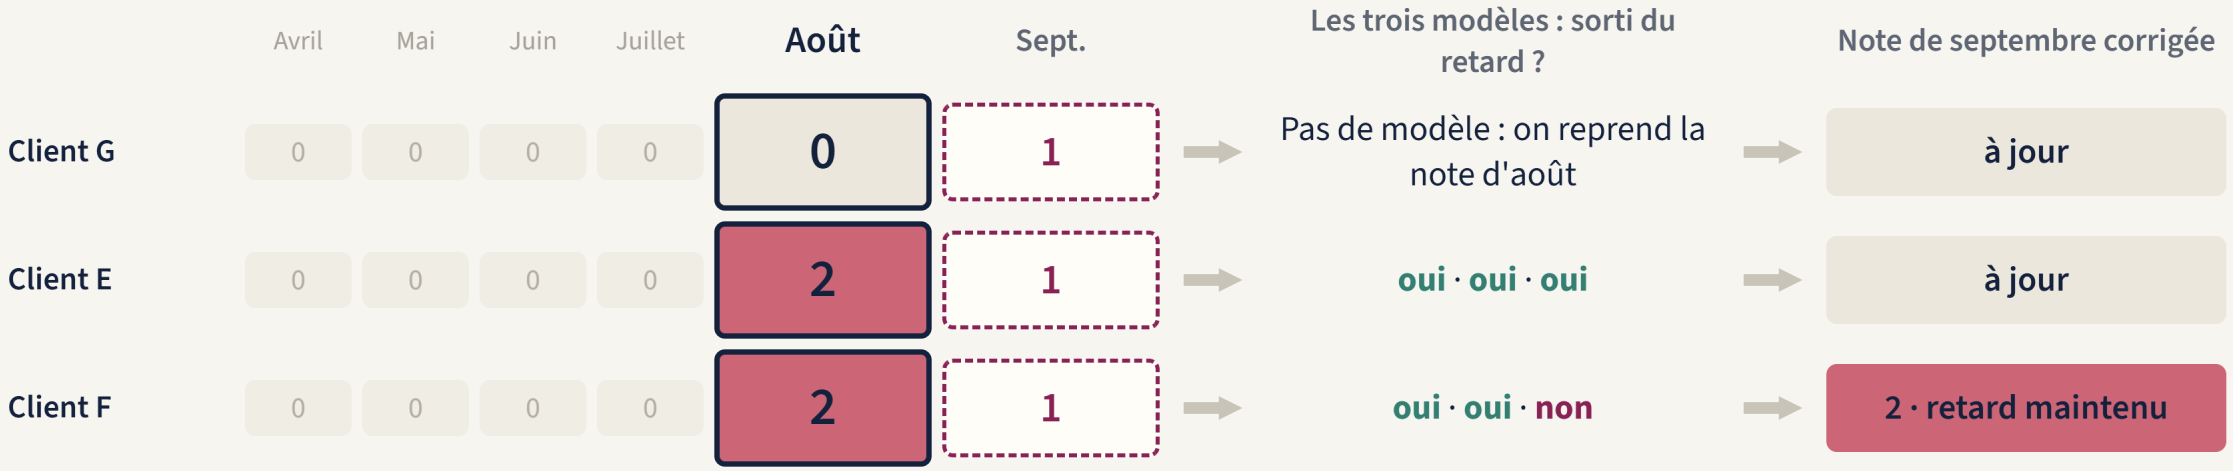
Comme un élève : des exercices corrigés, puis un examen jamais vu

Un client sur cinq est mis de côté dès le départ. Le modèle ne le voit jamais pendant l'apprentissage ; on ne l'interroge qu'une seule fois, à la fin. C'est cet examen qui dit si le modèle marche vraiment.

PREMIER USAGE DU MODÈLE

Corriger la note « 1 » de septembre

« 1 » = une note d'attente : la banque n'a pas encore tranché, car le paiement d'octobre n'est pas connu.

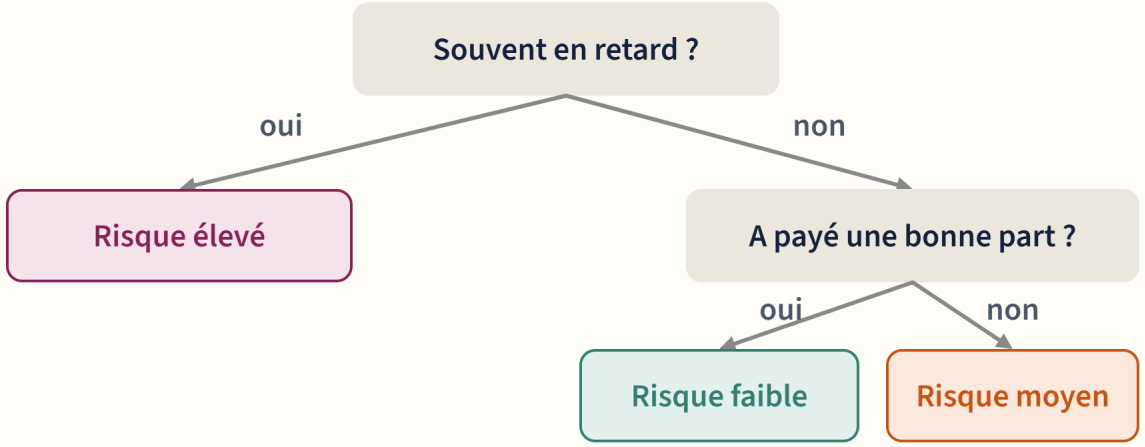


Exemples pour illustrer. En septembre, 3 086 clients ont une note « 1 » : 1 264 étaient à jour en août ; 1 822 étaient en retard, dont 199 en sortent et 1 623 restent en retard.

SECOND USAGE DU MODÈLE

Classer les clients que les règles ont laissés

Un arbre de décision, pour illustrer



CatBoost, le modèle retenu : des centaines de petits arbres qui votent ensemble, chacun corrigeant les erreurs des précédents.

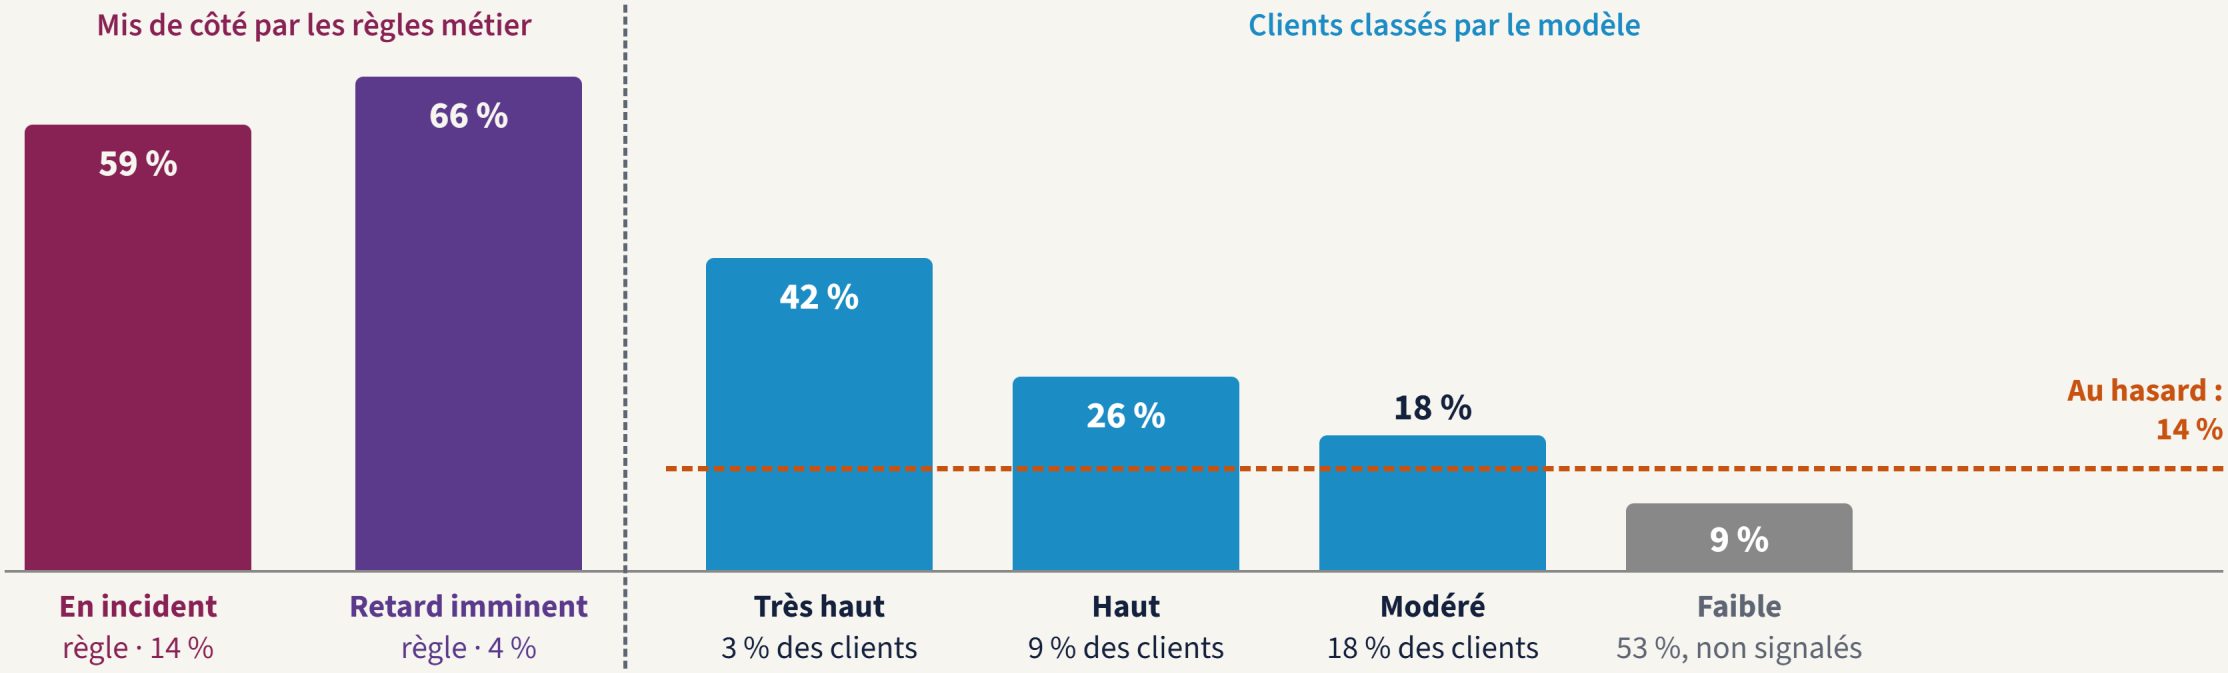
Les clients laissés au modèle
ceux que les règles n'ont pas retenus

Une note de risque
du plus risqué au moins risqué

- **Très haut risque**
- **Haut risque**
- **Risque modéré**
- **Risque faible**

LES RÈGLES, PUIS LE MODÈLE POUR LES AUTRES CLIENTS

Des niveaux de risque bien séparés



Un client « très haut risque » ne paie pas près de cinq fois plus souvent qu'un client « risque faible » : quatre sur dix, contre moins d'un sur dix.

Part des clients qui ne paient pas, par niveau ; pointillés orange : un client pris au hasard parmi ceux classés par le modèle, 14 %. 27 202 clients, chacun noté par un modèle qui ne l'avait jamais vu. Sans l'âge, le genre ni le statut marital.

DÉMONSTRATION EN DIRECT

Deux démos, sur des clients que les modèles n'ont jamais vus

Démo 1 · le système du projet

Données du projet, nettoyées : 5 441 clients

↓

Les règles : en incident ou en retard imminent ? Prédit en défaut

↓

Le modèle pour les autres : un niveau de risque

Démo 3 · sans le travail du projet

Base de données : les 30 000 clients bruts, lus par l'API

↓

Un modèle sur les données brutes : 9 niveaux de risque

↓

Comparé aux règles : à nombre égal d'alertes, qui a raison ?

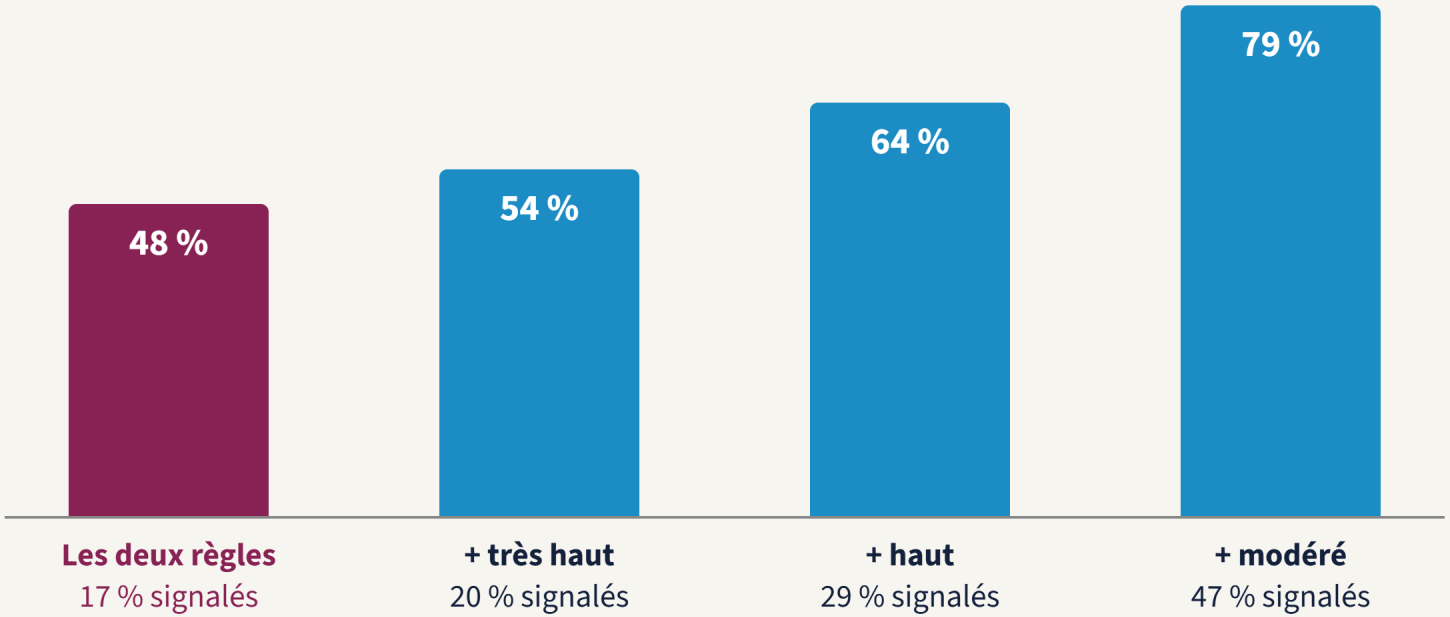
Dans les deux cas, **une personne décide** : le niveau de risque l'aide à choisir qui surveiller en premier.

risklens-ml.streamlit.app

LA RÉPONSE

Oui, en partie

Part des défauts trouvés, en signalant de plus en plus de clients



Face à l'étude de 2009

0,79 / 0,77

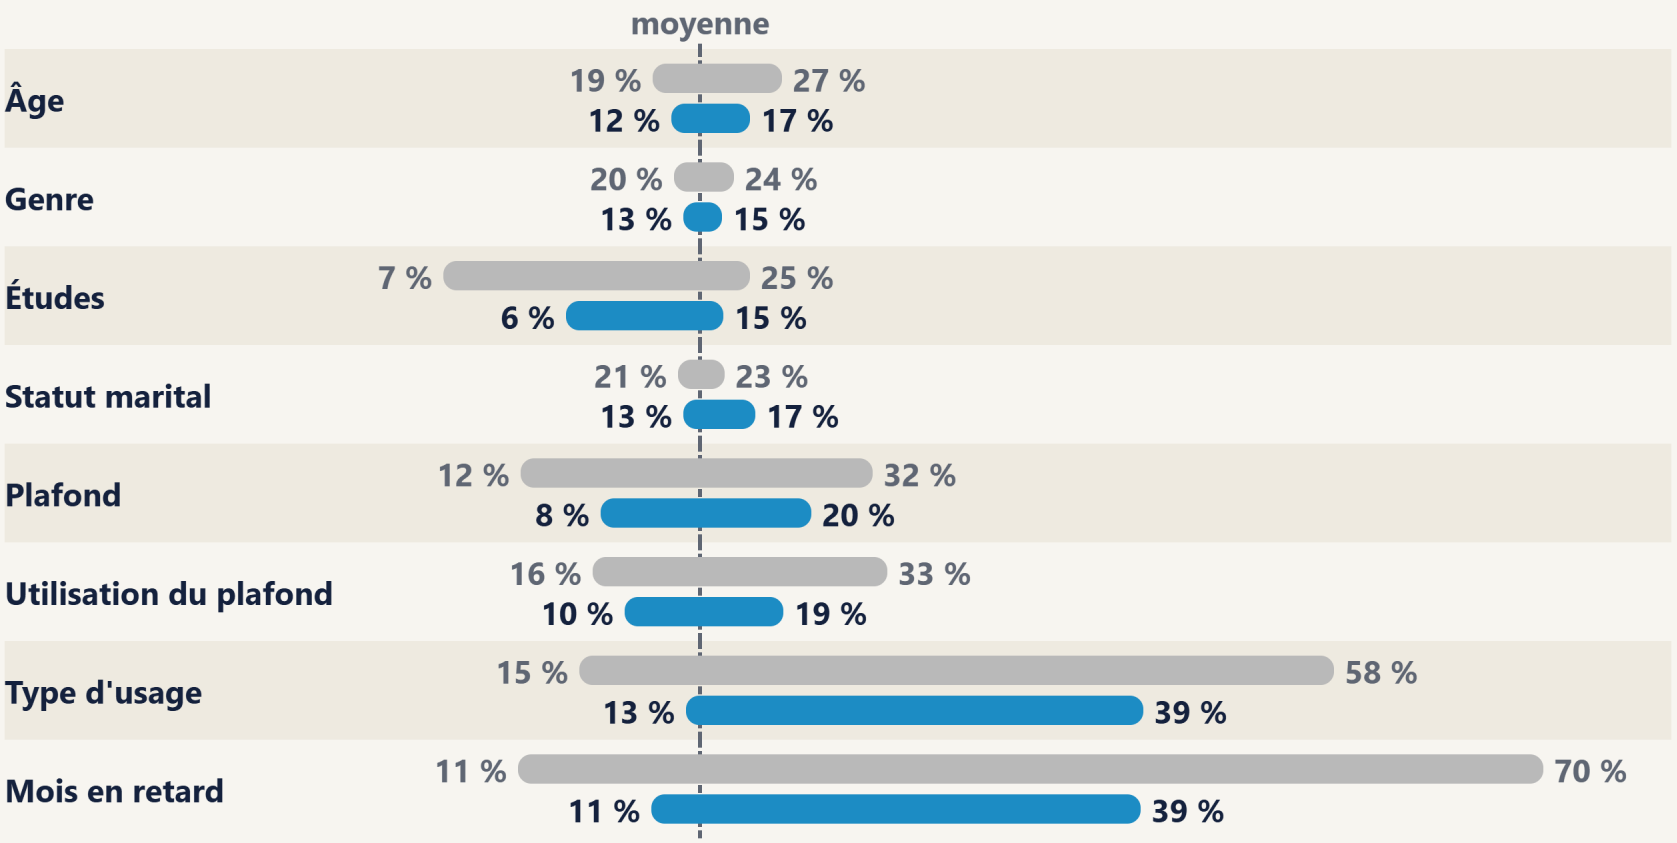
Sur 100 paires d'un client qui ne paiera pas et d'un qui paiera, le système classe 79 fois le premier comme plus risqué ; l'étude, 77. Au hasard : 50.

Le comportement classe bien les clients, mais ne désigne pas à coup sûr : même en tête de liste du modèle, plus d'un client signalé sur deux paie.

Barres : 27 202 clients, chacun noté par un modèle qui ne l'avait jamais vu. Note de classement de 0,79 (AUC) : 5 441 clients de la démo.

LES LIMITES

Les cas nets écartés, les écarts de risque fondent



Tous les clients
28 851 clients, moyenne 22 %

Clients laissés au modèle
22 459 clients, moyenne 14 %

---- Trait pointillé : la moyenne de chaque groupe

Il manque des données que seule la banque possède : **la définition exacte du défaut, le revenu, les crédits dans d'autres banques**

Part des clients qui ne paient pas, du groupe le moins risqué au plus risqué (groupes d'au moins 1 % des clients). Chaque série est alignée sur sa moyenne, à la même échelle.

LES RECOMMANDATIONS

Les règles d'abord, le modèle ensuite, une personne toujours

1. Les règles

Repérer les clients en incident et en retard imminent : simple, sans modèle, lisible par tout conseiller

2. Le modèle

Pour les autres clients, traiter d'abord les niveaux de risque les plus hauts

3. Une personne

Le niveau de risque aide à prioriser ; il ne décide jamais seul du sort d'un client

Pour aller plus loin, il faut de meilleures données plutôt qu'un meilleur modèle.

MERCI

Vos questions

Le site : risklens-ml.streamlit.app

Le code : github.com/johan-mac-59/RiskLens_ML

